

類別資料分析 第1章

The Analysis of Categorical Data

Chapter 1 : Introduction

- ◆授課教師：馬瀾嘉
- ◆成功大學統計學系暨數據科學研究所
- ◆大數據金融科技與數位資產管理實驗室主持人
- ◆Email：mcma@ncku.edu.tw

Introduction

*類別資料分析：針對資料中反應變數為類別變數 (Categorical variable) 和解釋變數可能是連續或類別變數的一種分析方法

*類別變數：類別資料可分為 Nominal data 和 Ordinal data

- 無序資料 (Nominal data) : e.g., 所屬政黨：1. 國民黨 / 2. 民進黨 / 3. 新黨 / 4. 無
- 有序資料 (Ordinal data) : e.g., 受傷程度：1. 無 / 2. 輕度 / 3. 中度 / 4. 嚴重
教育程度：1. 不識字 / 2. 國小 / 3. 國中 / 4. 高中 /
5. 大專 / 6. 大專以上

*分析資料時應先觀察資料有幾個變項，變項是連續變數或類別變數，是否獨立或相關，若為獨立的連續變數是否是常態分配，再進一步選擇適當的分析方法。

Introduction

- Poisson Sampling: $Y \sim \text{Poi}(\mu)$

$Y = Y(t)$: 在一段時間或特定空間，某事件發生的次數。

須滿足：1. $Y(0) = 0$

$$2. P[Y(h) = 1] = \mu h + o(h) \Leftrightarrow \lim_{h \rightarrow 0} \frac{P[Y(h)=1] - \mu h}{h} = 0$$

3. $P[Y(h) \geq 2] = o(h)$: 在非常短的瞬間或很小空間，事件發生超過一次的機率幾乎為 0

4. $P[Y(s+t) - Y(s) = n | Y(s) = m] = P[Y(s+t) - Y(s) = n]$: Independent increment

(不重疊的時間區間內，事件發生的次數彼此獨立)

Introduction

- Poisson Sampling: $Y \sim \text{Poi}(\mu)$

a. $P(Y = k) = \frac{e^{-\mu} \mu^k}{k!}, k = 0, 1, 2, \dots$

b. $E(Y) = \mu$

c. $\text{Var}(Y) = \mu$: 卜瓦松分配的變異數和平均數相等，故平均數越大，卜瓦松隨機變數分散程度越大

d. 若某計數隨機變數變異數大於平均數，則稱為 Over dispersion

e. $\frac{Y - \mu}{\sqrt{\mu}} \rightarrow N(0, 1) \text{ as } \mu \rightarrow \infty$

$$\text{pf} : Y_1, \dots, Y_\mu \stackrel{\text{i.i.d}}{\sim} \text{Poi}(1) \Rightarrow Y = \sum_{i=1}^{\mu} Y_i \sim \text{Poi}(\mu)$$

$$\Rightarrow \text{By C. L. T, } \frac{\sum_{i=1}^{\mu} Y_i - \mu}{\sqrt{\mu}} = \frac{Y - \mu}{\sqrt{\mu}} \sim N(0, 1)$$

Introduction

- **Binomial Sampling:** $Y \sim \text{Bin}(n, p)$

Y : 獨立且具相同分配的實驗進行 n 次，每次實驗只有兩種可能結果：成功或失敗，

Y 為 n 次中成功的次數。

a. $P(Y = k) = \binom{n}{k} \cdot p^k \cdot (1 - p)^{n-k}, k = 0, 1, 2, \dots, n$

b. $E(Y) = np$

c. $\text{Var}(Y) = np(1 - p)$: 二項分配的變異數較平均數小

d. $\frac{Y - np}{\sqrt{np(1-p)}} \rightarrow N(0, 1)$ as $n \rightarrow \infty$ st. $np > 5$ and $n(1 - p) > 5$

Introduction

- **Multinomial Sampling:** $(Y_1, Y_2, \dots, Y_k) \sim \text{Mult}(n, p_1, p_2, \dots, p_k)$

Y_i : 每次實驗有 k 種可能結果， Y_i 為第 i 種結果的次數

a. $P(Y_1 = y_1, \dots, Y_k = y_k) = \frac{n!}{\prod_{i=1}^k y_i!} \prod_{i=1}^k p_i^{y_i}, \sum_{i=1}^k y_i = n, \sum_{i=1}^k p_i = 1$ $Y_i \sim \text{Bin}(n, p_i)$

b. $E(Y_i) = np_i$

c. $\text{Var}(Y_i) = np_i(1 - p_i)$

d. $\text{Cov}(Y_i, Y_j) = -np_i p_j$ if $i \neq j$

Introduction

- **Inference for a proportion**

- 概似函數 (Likelihood function) : 觀測資料的機率函數 · 但視為參數的函數

e. g. $Y \sim \text{Bin}(n, p) \Rightarrow \ell(p) = P(Y = y) = \binom{n}{y} \cdot p^y \cdot (1 - p)^{n-y}$

if $n = 10, y = 0$, $\ell(p) = (1 - p)^{10}$: p 的函數

- 最大概似估計量 (Maximum likelihood estimator, MLE)

$$\max_{0 \leq p \leq 1} \ell(p) \Rightarrow \frac{\partial}{\partial p} \ell(p) \stackrel{\text{let}}{=} 0 \Rightarrow \text{解 } p \text{ 即為 MLE}$$

Introduction

- ***Inference for a proportion**

- 最大概似估計量 (Maximum likelihood estimator, MLE)

e. g. $Y \sim \text{Bin}(n, p) \Rightarrow \ell(p) = P(Y = y) = \binom{n}{y} \cdot p^y \cdot (1 - p)^{n-y}$

$$\Rightarrow L(p) = \ln \ell(p) = \ln \binom{n}{y} + y \cdot \ln p + (n - y) \cdot \ln(1 - p)$$

$$\Rightarrow \frac{\partial}{\partial p} L(p) = \frac{y}{p} - \frac{n-y}{1-p} = 0 \quad \Rightarrow \hat{p} = \frac{y}{n} : \text{MLE of } p$$

Introduction

*Inference for a proportion

- 最大概似估計量 (Maximum likelihood estimator, MLE)

$$\text{e. g. } Y \sim \text{Poi}(\mu) \Rightarrow \ell(\mu) = P(Y = y) = \frac{e^{-\mu} \mu^y}{y!}$$

$$\Rightarrow L(\mu) = \ln \ell(\mu) = -\mu + y \cdot \ln \mu - \ln(y!)$$

$$\Rightarrow \frac{\partial}{\partial \mu} L(\mu) = -1 - \frac{y}{\mu} = 0 \quad \Rightarrow \hat{\mu} = y : \text{MLE of } \mu$$

Introduction

*Test for a proportion

$$(1) H_0: p = p_0 \text{ vs. } H_1: p \neq p_0$$


$$(2) Z = \frac{\hat{p} - p_0}{\sqrt{\frac{p_0(1-p_0)}{n}}} \rightarrow N(0, 1) \text{ under } H_0: p = p_0 \text{ as } n \rightarrow \infty \text{ s. t. } np > 5 \text{ and } n(1-p) > 5$$

$$(3) \text{ Reject } H_0 \text{ if } Z > C_1 \text{ or } Z < C_2$$

$$\alpha = P(\text{Reject } H_0 | H_0 \text{ is true}) = P(Z > C_1 | p = p_0) + P(Z < C_2 | p = p_0)$$

$$\Rightarrow C_1 = Z_{\frac{\alpha}{2}} = \Phi^{-1}\left(1 - \frac{\alpha}{2}\right), \quad C_2 = Z_{1-\frac{\alpha}{2}} = \Phi^{-1}\left(\frac{\alpha}{2}\right)$$

$$\text{if } \alpha = 0.05 \quad \Rightarrow \quad C_1 = 1.96, \quad C_2 = -1.96$$



$$\Phi(x) = \int_{-\infty}^x \frac{1}{\sqrt{2\pi}} e^{-\frac{t^2}{2}} dt$$

Introduction

*Confidence Interval for a proportion

$$\begin{aligned} \because 1 - \alpha = P(|Z| < Z_{\frac{\alpha}{2}}) &\Rightarrow -Z_{\frac{\alpha}{2}} < \frac{\hat{p} - p}{\sqrt{\frac{\hat{p}(1-\hat{p})}{n}}} < Z_{\frac{\alpha}{2}} \\ &\Rightarrow \hat{p} - Z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} < p < \hat{p} + Z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \end{aligned}$$

$\therefore$ The C.I. of p is $\hat{p} \pm Z_{\frac{\alpha}{2}} \cdot \hat{\sigma}(\hat{p})$, where $\hat{\sigma}(\hat{p}) = \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$

$Z_{\frac{\alpha}{2}} \cdot \hat{\sigma}(\hat{p}) = e$: 誤差界限

*The sample size requirement

若已知誤差界限不得超過 e_0 ，可反求所需的樣本數：

$$Z_{\frac{\alpha}{2}} \cdot \sqrt{\frac{\hat{p}(1-\hat{p})}{n}} \leq e_0 \Rightarrow n \geq \frac{Z_{\frac{\alpha}{2}}^2 \cdot \hat{p}(1-\hat{p})}{e_0^2}$$

Introduction

*Test for a proportion (小樣本情形 · $n \leq 20$)

例：某人聲稱他投球的命中率為 50%，今投 10 球中了 3 球。

(1) 是否有證據顯示命中率不為 50%？($\alpha = 0.05$)

(2) 是否有證據顯示命中率不到 50%？($\alpha = 0.05$)

解：(1) $H_0: p = 0.5$ vs. $H_1: p \neq 0.5 \Rightarrow p\text{-value} = P(X \leq 3 | p = 0.5) + P(X \geq 7 | p = 0.5)$

$$\begin{aligned} &= \sum_{k=0}^3 \binom{10}{k} 0.5^k 0.5^{10-k} + \sum_{k=7}^{10} \binom{10}{k} 0.5^k 0.5^{10-k} \\ &= 0.3438 > \alpha = 0.05 \quad \therefore \text{Do not reject } H_0 \end{aligned}$$

(2) $H_0: p = 0.5$ vs. $H_1: p \leq 0.5$

$$\Rightarrow p\text{-value} = P(X \leq 3 | p = 0.5) = \sum_{k=0}^3 \binom{10}{k} 0.5^k 0.5^{10-k} = 0.1719 > \alpha$$

$\therefore$ Do not reject H_0

分析基本概念

研究目的	統計分析方法
描述資料特性	*連續資料：Mean $\pm$ SD (資料對稱) 或 Median & IQR (資料不對稱) *類別資料：Proportion或 Percentage
一組資料平均值檢定	*連續資料：One sample t test 或 Wilcoxon test *類別資料：Binomial test 或 Proportion test (Binary outcome)
建立關係式作預測	*反應變數為連續資料：Regression analysis (1個反應變數) 或 Canonical correlation analysis (多個反應變數做線性組合) *反應變數為類別資料：Logistic regression analysis *反應變數為 Censored Data：Cox regression analysis *反應變數有群集相關：GEE (Generalized Estimating Equation) *反應變數為連續資料：Structure equation model (多個反應變數分組建立關係式)

分析基本概念

研究目的	統計分析方法
兩變數間是否相關	*各種檢定見下表
各變量組合與分組	*Principal components analysis 或 Factor analysis
樣本之分類	*Discriminant analysis, SVM, CNN, VoxCNN, ResNet或CART, Random Forest(類別已知) ; Clustering analysis(類別未知)

兩變數間是否相關

Unpaired Data	類別變數	連續變數1
類別變數	*大樣本：卡方檢定 *小樣本：Fisher's exact test	*兩組平均值比較：Two sample t test *三組以上平均值比較：ANOVA If sig. — Multiple comparison
連續變數1		*Pearson correlation coefficient
連續變數2	*兩組平均值比較： Wilcoxon signed-rank test 或 Mann-Whitney U test *三組以上平均值比較：Kruskal - Wallis test	

連續變數1: 呈常態分配的小樣本資料或大樣本資料, 使用Parametric method

連續變數2: 不呈常態分配的小樣本資料 (如：ordinal data , 使用 Nonparametric method)

兩變數間是否相關

Paired Data	類別變數	連續變數2
類別變數	*McNemar's test	
連續變數1	*兩組平均值比較：Paired t test *三組以上平均值比較：Repeated measure test	
連續變數2	*兩組平均值比較： Wilcoxon test 或 Signed test *三組以上平均值比較：Friedman test	*Spearman correlation coefficient

連續變數1: 呈常態分配的小樣本資料或大樣本資料, 使用Parametric method

連續變數2: 不呈常態分配的小樣本資料 (如：ordinal data , 使用 Nonparametric method)

報告撰寫

*封面 / 標題 / 目錄

*摘要 (含研究背景、方法、結果、結論)、關鍵詞

*問題背景之陳述—研究動機、研究目的、研究假說

*材料及方法—研究設計、研究母體、分析方法

*結果—應精簡、正確、合理

*討論—和文獻作比較、主要發現 & 研究限制

*致謝—感謝經費贊助單位或對報告有貢獻但未掛名的人員

*附表 / 附圖—圖表應精簡

*參考文獻—應依照期刊文獻一般格式編排