

Summary of Missing Data in Clinical Research: A Tutorial on Multiple Imputation

在以前，處理遺失資料的方法通常有幾種：

- (1) Complete case analysis：刪除全部有遺失資料的觀察值。
- (2) mean value imputation：使用該變數的平均值進行插補。缺點是會降低資料集的變異，低估了估計參數的標準差，也忽略了眾多變數之間的相關性。
- (3) conditional mean imputation：使用迴歸模型，依序對各變數的遺失值進行迴歸預測。
- (4) modification of conditional mean imputation：方法（3）的改進，從迴歸模型得到具有遺失值的變數的條件分配，並從分配中隨機抽取一個值進行插補。

作者提到，方法（2）～（4）通常建議用在「隨機試驗中的基底變數」（mean value imputation and conditional-mean imputation are recommended for handling missing values of baseline covariates in randomised trial only.）

在這篇文章中，作者重點介紹多重插補法（Multiple imputation using MICE (Multivariate Imputation by chained equations)）：

1. 將所有遺失值進行插補：以隨機抽樣的方式，從該遺失的變數抽取其中一個並補值。值得注意的是，這個步驟所補的值，都會被後面的演算法覆寫。
2. 取第一個有遺失值的變數作為 Y，其他變數作為 X，配適一個迴歸模型，並使用此迴歸模型預測估計值。
3. 針對全部有遺失值的變數，重複進行步驟（2）。步驟（2）、（3）合稱為 1 個循環，最後會得到一個估計的資料集。
4. 重複步驟（2）和（3）大約 5～20 次，最終得到的估計值就插補在原本的遺失值中，並得到第一個插補資料集。
5. 重複步驟（2）～（4）M 次，以產生 M 個插補資料集。通常建議 M = 5～10，但現今計算資源已便宜許多，M = 20～100 也很常見。

多重插補後，我們會得到 M 個插補資料集。對每個插補資料集進行模型建立（會得到 M 個模型），最後模型的估計參數，則是計算 M 個模型的估計參數的平均。

其他應注意的點：

1. 研究者必須區分 2 種模型：插補模型 (imputation model) 和分析模型

(analysis model)。插補模型是用來補值，而分析模型是用來得到感興趣研究的結果。

2. 要將所有在分析模型中有用到的變數包含在插補模型裡，包含 Y (outcome variable)。若沒有做到，可能會造成參數估計結果有誤差。

(a) 如果 Y 是 time-to-event outcome，則使用 cumulative survivor function 將 time-to-event variable 進行轉換。

(b) 如果是長期追蹤資料，假設第二次測量的資料遺失，也要將第二次以後的資料（例：第三次測量資料）納入插補模型裡。

3. 假設有些變數是從其他變數計算得來的（例如：BMI = 體重/身高平方），有 2 種方法：

(a) 先插補體重/身高，不插補 BMI。插補完體重/身高後，在計算得出 BMI。此方法的缺點是會造成參數估計誤差。

(b) 將 BMI 視為另外一個變數，直接跟著其他變數一起進行插補。此方法缺點是會造成 BMI 和公式不符，但優點是參數估計較（a）精準。

4. 如果 outcome variable 有遺失值，von Hippel 提出一個“Multiple imputation, then deletion” (MID)的方法。在此方法中，所有觀察值都包含在插補模型中（包括 Y（outcome variable）有遺失值的觀察值），但在分析模型中，Y 有遺失值的觀察值則不會包含在分析資料裡。這是為了避免一些較差的補值在 Y（outcome variable）上，可能會導致分析結果變差。要注意的是，MID 方法不適用於不包含在分析模型裡的輔助變數（auxiliary variables, and not included in the analysis model）和 Y 有強相關的情形。